
TP 2.2 - GENERADORES PSEUDOALEATORIOS DE DISTINTAS DISTRIBUCIONES DE PROBABILIDAD

Alvaro Tomasino

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
atomasino08@gmail.com

Juan Bautista Martinelli

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
martinellij4@gmail.com

Tomás Aguilera

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
tomas.aguilera.27@gmail.com

Melina Aronson

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
melinaaronson@gmail.com

9 de junio de 2026

ABSTRACT

El objetivo de este informe es, con los generadores usados en su anterior parte, empezar a utilizarlos en distintos contextos para finalizar con nuestro estudio.

Keywords Simulación · generadores pseudoaleatorios · distribuciones de probabilidad · transformada inversa · método de rechazo

1. Introducción

Al emplear los generadores como los programamos anteriormente, estos van a generar valores uniformes continuos entre 0 y 1.

Entonces ¿Cómo hacemos para generar valores de distintas distribuciones? La solución es apoyarse en un material elaborado por Thomas Naylor para redescubrir el mecanismo de los generadores, y poder implementarlo en los casos que se desea y de distintas probabilidades.

A continuación, durante todo el informe, se desarrollan las bases teóricas de las siguientes distribuciones, con el desarrollo de los diferentes métodos de generación, y su implementación y test en código Python según indica la siguiente tabla.

Distribución de Probabilidad	Tipo	T. Inversa	M. Rechazo	Código	Testeo
UNIFORME	continua	sí	sí	sí	sí
EXPONENCIAL	continua	sí	sí	no	sí
GAMMA	continua	sí	no	no	no
NORMAL	continua	sí	sí	sí	sí
PASCAL	discreta	sí	no	no	no
BINOMIAL	discreta	sí	no	no	sí
HIPERGEOMÉTRICA	discreta	sí	no	no	no
POISSON	discreta	sí	no	no	sí
EMPÍRICA DISCRETA	discreta	sí	no	no	sí

Cuadro 1: Listado de distribuciones y tareas a realizar con cada una.

2. Metodología

2.1. Distribución de Probabilidades (deducción matemática)

2.1.1. Distribución de Probabilidad Uniforme

Es una familia de distribuciones de probabilidad para variables aleatorias, tales que para cada miembro de la familia todos los intervalos de igual longitud en la distribución en su rango son igualmente probables. El dominio está definido por dos parámetros, **a** y **b**, que son sus valores mínimo y máximo respectivamente.

Notación Si X es una variable aleatoria continua con distribución uniforme continua se nota como:

$$X \sim U(a, b) \quad \text{o} \quad X \sim \text{Uniforme}(a, b) \quad (1)$$

Función de densidad Si $X \sim U(a, b)$ entonces la función de densidad es:

$$f_X(x) = \frac{1}{b-a} \quad \forall x \in [a, b] \quad (2)$$

2.1.2. Distribución de Probabilidad Exponencial

La distribución exponencial es una distribución continua que se utiliza para modelar tiempos de espera para la ocurrencia de un cierto evento, siendo un caso particular de la distribución gamma. Esta distribución al igual que la distribución geométrica tiene la propiedad de pérdida de memoria.

Notación Si X es una variable aleatoria continua con distribución exponencial continua, y $\lambda > 0$ se nota como:

$$X \sim \text{Exp}(\lambda) \quad \text{con } \lambda > 0 \quad (3)$$

Función de densidad Si $X \sim \text{Exp}(\lambda)$ entonces la función de densidad es:

$$f_X(x) = \lambda e^{-\lambda x} \quad \forall x \geq 0 \quad (4)$$

2.1.3. Distribución de Probabilidad Gamma

La distribución Gamma es una distribución continua utilizada para modelar tiempos de espera, confiabilidad de sistemas y diversos fenómenos donde se acumulan eventos aleatorios.

Su distribución depende de dos parámetros:

- **α (alfa):** parámetro de forma (*shape*), $\alpha > 0$.
- **β (beta):** parámetro de escala (*scale*), $\beta > 0$.

Siendo su denotación:

$$X \sim \Gamma(\alpha, \beta) \quad (5)$$

Función de Densidad de Probabilidad

$$f(x) = \frac{1}{\Gamma(\alpha) \beta^\alpha} x^{\alpha-1} e^{-x/\beta} \quad (6)$$

Para $x > 0$, donde:

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt \quad (7)$$

Obtención de la Función Acumulada La función acumulada se define como:

$$F(x) = P(X \leq x) \quad (8)$$

Por definición: $F(x) = \int f(t) dt$.

Sustituyendo la Función de Densidad:

$$F(x) = \int_0^x \frac{1}{\Gamma(\alpha) \beta^\alpha} t^{\alpha-1} e^{-t/\beta} dt \quad (9)$$

Sacando las constantes:

$$F(x) = \frac{1}{\Gamma(\alpha) \beta^\alpha} \int_0^x t^{\alpha-1} e^{-t/\beta} dt \quad (10)$$

Realizando el cambio de variables:

$$u = \frac{t}{\beta}, \quad t = \beta u, \quad dt = \beta du \quad (11)$$

Queda:

$$F(x) = \frac{1}{\Gamma(\alpha)} \int_0^{x/\beta} u^{\alpha-1} e^{-u} du \quad (12)$$

Llamando a la integral $\gamma(\alpha, z)$, quedaría finalmente:

$$F(x) = \frac{\gamma(\alpha, x/\beta)}{\Gamma(\alpha)} \quad (13)$$

2.1.4. Distribución de Probabilidad Normal

La distribución normal es una distribución continua que aparece con más frecuencia en estadística. La gráfica de su función de densidad tiene una forma acampanada y es simétrica respecto a un determinado parámetro estadístico. Esta curva se conoce como campana de Gauss.

Notación Si X es una variable aleatoria continua con distribución normal, se nota como:

$$X \sim N(\mu, \sigma^2) \quad (14)$$

donde los parámetros de entrada son la media (μ) y la varianza (σ^2).

Función de densidad La función de densidad de probabilidad está dada por la ecuación de la campana de Gauss:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad (15)$$

Para el caso de la distribución normal estándar ($\mu = 0$ y $\sigma = 1$), la fórmula se simplifica a:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \quad (16)$$

Obtención de la función acumulada La función de distribución acumulada calcula la probabilidad de que una variable aleatoria continua X sea menor o igual a un valor específico x :

$$F(x) = P(X \leq x) \quad (17)$$

Para una distribución normal, se define a través de la integral de su función de densidad de probabilidad:

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2} dt \quad (18)$$

2.1.5. Distribución de Probabilidad Pascal

También conocida como **distribución binomial negativa**, es una distribución discreta que modela el número de fracasos que ocurren antes de obtener un número fijo de éxitos en una secuencia de ensayos de Bernoulli independientes.

Parámetros La distribución depende de dos parámetros:

- r : número fijo de éxitos que se desean obtener ($r > 0$).
- p : probabilidad de éxito en cada ensayo ($0 < p < 1$).

Denotada como:

$$X \sim \text{Pascal}(r, p) \quad (19)$$

donde X representa el número de fracasos antes de alcanzar el r -ésimo éxito.

Función de Probabilidad La probabilidad de obtener exactamente x fracasos antes del r -ésimo éxito es:

$$P(X = x) = \binom{x+r-1}{r-1} p^r (1-p)^x \quad \text{para } x = 0, 1, 2, \dots \quad (20)$$

Obtención de la Función Acumulada Se define como: $F(x) = P(X \leq x)$. Por definición:

$$F(x) = \sum_{k=0}^x \binom{k+r-1}{r-1} p^r (1-p)^k \quad (21)$$

Y desarrollando algunos términos:

$$F(x) = p^r + r p^r (1-p) + \binom{r+1}{r-1} p^r (1-p)^2 + \dots \quad (22)$$

En forma general:

$$F(x) = \sum_{k=0}^x \binom{k+r-1}{r-1} p^r (1-p)^k \quad (23)$$

Obtención de la Función Inversa Partiendo de $u = F(x)$ con $u \sim U(0, 1)$, debemos encontrar el menor valor entero x tal que:

$$F(x) \geq u \quad \text{es decir: } x = F^{-1}(u) \quad (24)$$

2.1.6. Distribución de Probabilidad Binomial

La distribución binomial es una distribución de probabilidad discreta que cuenta el número de éxitos en una secuencia de n ensayos de Bernoulli independientes entre sí con una probabilidad fija p de ocurrencia de éxito entre los ensayos. Un experimento de Bernoulli se caracteriza por ser dicotómico, es decir, solo dos resultados son posibles. A uno se lo llama “éxito” y tiene una probabilidad de ocurrencia p , y al otro se lo llama “fracaso” y tiene una probabilidad $q = 1 - p$.

Notación Si una variable aleatoria discreta X tiene una distribución binomial con parámetros $n \in \mathbb{N}$ y p con $0 < p < 1$, se nota como:

$$X \sim \text{Bin}(n, p) \quad (25)$$

Función de densidad Su función de densidad está dada por la función de probabilidad:

$$P[X = x] = \binom{n}{x} p^x (1 - p)^{n-x} \quad \text{para } x = 0, 1, 2, \dots, n \quad (26)$$

Obtención de la función acumulada La función de distribución acumulada está dada por:

$$F_X(x) = P[X \leq x] = \sum_{k=0}^{\lfloor x \rfloor} \binom{n}{k} p^k (1 - p)^{n-k} \quad \text{si } 0 \leq x \leq n \quad (27)$$

2.1.7. Distribución de Probabilidad Hipergeométrica

Es una distribución discreta que modela la probabilidad de obtener una determinada cantidad de éxitos al extraer elementos de una población finita sin reemplazo.

Parámetros La distribución depende de 3 parámetros:

- N : tamaño total de la población.
- K : número de elementos considerados éxitos dentro de la población.
- n : tamaño de la muestra extraída.

Se denota:

$$X \sim H(N, K, n) \quad (28)$$

donde X es el número de éxitos obtenidos en la muestra.

Función de Probabilidad Se define como:

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}} \quad (29)$$

donde $\binom{K}{x}$ representa las formas de elegir x éxitos, $\binom{N-K}{n-x}$ las formas de elegir los fracasos y $\binom{N}{n}$ el total de muestras posibles, con:

$$\max(0, n - (N - K)) \leq x \leq \min(n, K) \quad (30)$$

Obtención de la Función Acumulada Se define como: $F(x) = P(X \leq x)$. Por definición:

$$F(x) = \sum_{k=0}^x P(X = k) \quad (31)$$

Sustituyendo:

$$F(x) = \sum_{k=0}^x \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} \quad (32)$$

Finalmente:

$$F(x) = \frac{1}{\binom{N}{n}} \sum_{k=0}^x \binom{K}{k} \binom{N-K}{n-k} \quad (33)$$

2.1.8. Distribución de Probabilidad Poisson

La distribución de Poisson es una distribución de probabilidad discreta que expresa, a partir de una frecuencia de ocurrencia media, la probabilidad de que ocurra un determinado número de eventos durante cierto periodo de tiempo. Se especializa en la probabilidad de ocurrencia de sucesos con probabilidades muy pequeñas, o sucesos raros.

Notación Sea $\lambda > 0$ y X una variable aleatoria discreta; si X tiene una distribución de Poisson con parámetro λ , se nota como:

$$X \sim \text{Poisson}(\lambda) \quad \text{o} \quad X \sim \text{Poi}(\lambda) \quad (34)$$

Función de densidad Como la variable aleatoria X es discreta, no usa una función de densidad, sino una función de masa de probabilidad:

$$P[X = k] = \frac{e^{-\lambda} \lambda^k}{k!} \quad (35)$$

donde k es el número de ocurrencias del evento, y λ representa el número de veces que se espera que ocurra dicho fenómeno durante un intervalo dado.

Obtención de la función acumulada La función acumulada calcula la probabilidad de que ocurran x eventos o menos en un intervalo dado. Se obtiene sumando las probabilidades puntuales desde 0 hasta el valor de x :

$$P(X \leq x) = \sum_{k=0}^x \frac{e^{-\lambda} \lambda^k}{k!} \quad (36)$$

2.1.9. Distribución de Probabilidad Empírica Discreta

En algunas situaciones, ninguna de las distribuciones teóricas conocidas describe bien el comportamiento de los datos observados. En esos casos se usan las distribuciones empíricas, que permiten aproximar el comportamiento de un fenómeno a partir de frecuencias de datos recolectados directamente de la realidad.

Notación Sea X una variable aleatoria discreta que puede tomar un conjunto de valores específicos $b_1, b_2, \dots, b_n$. Asociada a cada valor, existe una probabilidad observada p_i tal que:

$$P(X = b_i) = p_i \quad (37)$$

Función de probabilidad La distribución se define por una tabla de frecuencias donde se listan los posibles resultados y sus probabilidades de ocurrencia. La suma de todas las probabilidades debe ser igual a la unidad:

$$\sum_{i=1}^n p_i = 1 \quad (38)$$

2.2. Método de la Transformada Inversa (deducción matemática)

El Método de la Transformada Inversa es una técnica para generar números aleatorios que sigan una distribución de probabilidad determinada a partir de números aleatorios uniformes en el intervalo $(0, 1)$. Es decir, tenemos:

$$r \sim U(0, 1) \quad (39)$$

Donde r es un número entre 0 y 1 generado a partir de una distribución Uniforme.

Queremos obtener una variable aleatoria X con una distribución específica arbitraria, cuya función de distribución acumulada es $F(x)$. La función acumulada $F(x)$ indica la probabilidad de que la variable X tome un valor menor o igual que x :

$$F(x) = \int_{-\infty}^x f(t) dt \quad F(x) = P(X \leq x) \quad (40)$$

Esta función de probabilidad acumulada está definida en el intervalo de 0 a 1.

El método consiste en aplicar la función inversa de la distribución acumulada para que x tenga un valor dado por la distribución deseada. Esto es, si generamos un valor uniforme r entre 0 y 1 y buscamos el valor x tal que:

$$r = F(x) = \int_{-\infty}^x f(t) dt \quad (41)$$

entonces:

$$F^{-1}(r) = x \quad (42)$$

$F^{-1}(r)$ es la transformación inversa o mapeo de r sobre el intervalo o dominio de x .

Gráficamente, dado el valor r_0 en el eje vertical de la función acumulada $F(x) = r$, su correspondiente x_0 en el eje horizontal es el valor generado con la distribución deseada. El criterio $P(X \leq x) = F(x) = P[r \leq F(x)] = P[F^{-1}(r) \leq x]$ equivale a resolver la ecuación en x en términos de r .

Este método cuenta con varias desventajas que se van a ir presentando a medida que lo vayamos aplicando a las diversas distribuciones. La principal desventaja es que no siempre existe una inversa analítica de la función de distribución acumulada $F(x)$, por ejemplo la distribución Gamma o la distribución normal estándar. Esto se resuelve aplicando métodos numéricos. Cuando la inversa no existe en forma explícita, hay que calcularla mediante algoritmos iterativos. Esto tiene un costo computacional elevado. Evaluar funciones logarítmicas, exponenciales o resolver ecuaciones numéricamente puede ser más lento que otros métodos de generación.

A continuación se deduce el método matemático para generar números aleatorios a partir de una distribución Uniforme para cada distribución mencionada en la sección anterior.

2.2.1. Distribución de Probabilidad Uniforme

Dada la función de densidad $f(x)$ de la distribución Uniforme $X \sim U(0, 1)$:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b \quad (43)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \int_a^x \frac{1}{b-a} dt = \frac{x-a}{b-a} \quad (44)$$

Dado un número aleatorio r generado por $r \sim U(0, 1)$, igualamos $F(x) = r$:

$$\frac{x-a}{b-a} = r \quad (45)$$

Buscamos $F^{-1}(r) = x$:

$$x = a + (b-a)r \quad (46)$$

Si $r \sim U(0, 1)$, entonces $F^{-1}(r) = a + (b-a)r = x$ tiene exactamente la función de distribución F . Para la distribución $U(0, 1)$, este caso es especialmente limpio porque $F(x)$ es lineal y su inversa se obtiene con álgebra directa, sin necesidad de métodos numéricos.

2.2.2. Distribución Exponencial

Dada la función de densidad $f(x)$ de la distribución Exponencial:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0 \quad (47)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \int_0^x \lambda e^{-\lambda t} dt = [-e^{-\lambda t}]_0^x = 1 - e^{-\lambda x} \quad (48)$$

Despejando x a partir de $F(x) = r$:

$$\begin{aligned} 1 - e^{-\lambda x} &= r \\ e^{-\lambda x} &= 1 - r \\ -\lambda x &= \ln(1 - r) \\ x &= -\frac{1}{\lambda} \ln(1 - r) \end{aligned} \quad (49)$$

Como $r \sim U(0, 1)$, entonces $(1 - r)$ también es $U(0, 1)$. Por lo tanto se puede escribir directamente:

$$x = -\frac{1}{\lambda} \ln(r) \quad (50)$$

2.2.3. Distribución Gamma

Dada la función de densidad $f(x)$ de la distribución Gamma:

$$f(x) = \frac{1}{\beta^k \Gamma(k)} x^{k-1} e^{-x/\beta}, \quad x \geq 0 \quad (51)$$

donde:

$$\Gamma(k) = \int_0^{\infty} t^{k-1} e^{-t} dt \quad (52)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \int_0^x \frac{1}{\beta^k \Gamma(k)} t^{k-1} e^{-t/\beta} dt \quad (53)$$

Debido a que para una distribución Gamma no se puede formular explícitamente una función de distribución acumulada, debemos considerar un método alternativo para generar valores de variable aleatoria con esta distribución.

Igualar $F(x) = r$ y despejar x **no tiene solución algebraica** en el caso general. No existe una fórmula cerrada del tipo $x = \text{fórmula}(r, k, \beta)$. Esto significa que $F^{-1}(r)$ debe obtenerse **numéricamente**, lo cual hace que la transformada inversa directa sea costosa computacionalmente.

Cuando k no es entero, las opciones son:

- **Métodos numéricos** para invertir $F(x)$ iterativamente (bisección, Newton-Raphson).
- **Algoritmos especializados** como el de Cheng (1977), basado en el método de rechazo, que es el más usado en la práctica para $k > 1$.

Cuando k es un entero positivo, existe un camino alternativo muy elegante. Se puede demostrar que si:

$$X_1, X_2, \dots, X_k \sim \text{Exponencial}(\lambda) \quad \text{independientes} \quad (54)$$

entonces su suma:

$$X = X_1 + X_2 + \dots + X_k \sim \text{Gamma}(k, \beta = \frac{1}{\lambda}) \quad (55)$$

A esto se le conoce como **distribución de Erlang**. Aplicando la transformada inversa de cada exponencial (que sí tiene forma cerrada):

$$X = -\frac{1}{\lambda} \sum_{i=1}^k \ln(r_i) = -\frac{1}{\lambda} \ln\left(\prod_{i=1}^k r_i\right) \quad (56)$$

2.2.4. Distribución Normal

Dada la función de densidad $f(x)$ de la distribución Normal:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad -\infty < x < \infty \quad (57)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2} dt \quad (58)$$

Al igual que la Gamma, esta integral no tiene forma cerrada. Se expresa en términos de la función error:

$$F(x) = \frac{1}{2} \left[1 + \text{erf}\left(\frac{x-\mu}{\sigma\sqrt{2}}\right) \right] \quad (59)$$

Por lo tanto $F^{-1}(r)$ tampoco tiene forma algebraica directa, y el camino de la transformada inversa pura requeriría métodos numéricos.

Las soluciones a esto son el método de rechazo para la Normal, que opera sobre la normal estándar y usa como función envolvente una distribución que es fácil de muestrear (típicamente una combinación de uniformes y exponenciales), y el **Método de la suma de uniformes** (Teorema Central del Límite).

El Teorema Central del Límite establece que la suma de muchas variables aleatorias independientes con cualquier distribución tiende a una normal. Entonces, si sumamos K uniformes(0, 1):

$$S = r_1 + r_2 + \cdots + r_K \quad (60)$$

para K suficientemente grande, S se comporta aproximadamente como una normal.

Cada $r_i \sim \text{Uniforme}(0, 1)$ tiene:

$$\theta = \frac{a+b}{2} = \frac{1}{2}, \quad \sigma = \frac{b-a}{\sqrt{12}} = \frac{1}{\sqrt{12}} \quad (61)$$

Por el TLC, la suma de K de ellas tiene:

$$E\left(\sum r_i\right) = \frac{K}{2}, \quad \text{Var}\left(\sum r_i\right) = \frac{K}{12} \quad (62)$$

Estandarizando (restando la media y dividiendo por el desvío):

$$z = \frac{\sum_{i=1}^K r_i - K/2}{\sqrt{K/12}} \quad (63)$$

Este z es aproximadamente $N(0, 1)$, y luego $x = \mu + \sigma z$ da cualquier normal deseada.

Por definición z es un valor de variable aleatoria con distribución normal estándar que se puede escribir de la forma:

$$z = \frac{x - \mu_x}{\sigma_x} \quad (64)$$

Igualando las últimas dos ecuaciones obtenemos:

$$\frac{x - \mu_x}{\sigma_x} = \frac{\sum_{i=1}^K r_i - K/2}{\sqrt{K/12}} \quad (65)$$

y resolviendo para x , se tiene que:

$$x = \sigma_x \left(\frac{12}{K}\right)^{1/2} \left(\sum_{i=1}^K r_i - \frac{K}{2}\right) + \mu_x \quad (66)$$

Así se pueden generar valores aleatorios con distribución normal con promedio μ_x y desvío σ_x a partir de K valores generados por una distribución uniforme.

2.2.5. Distribución Pascal

Dada la función de densidad $f(x)$ de la distribución Pascal:

$$P(X = x) = \binom{x+r-1}{r-1} p^r (1-p)^x \quad (67)$$

con función de distribución acumulada $F(x)$:

$$F(x) = P(X \leq x) = \sum_{k=s}^x \binom{k-1}{s-1} p^s (1-p)^{k-s} \quad (68)$$

Como $F(x)$ es discreta, no se puede despejar x algebraicamente. En su lugar, dado $r \sim \text{Uniforme}(0, 1)$, se busca el menor x tal que $F(x) \geq r$:

$$F(x-1) < r \leq F(x) \quad (69)$$

Es decir, se recorre la función acumulada de izquierda a derecha hasta que supera a r por primera vez. Su algoritmo es el siguiente:

1. Comenzar en $x = s$ (el mínimo posible).
2. Calcular $P(X = x)$ con la fórmula.
3. Acumular $F(x) = F(x-1) + P(X = x)$.
4. Si $F(x) \geq r$, devolver x como valor generado.
5. Si no, incrementar $x = x + 1$ y volver al paso 2.

2.2.6. Distribución Binomial

Dada la función de densidad $f(x)$ de la distribución Binomial:

$$P[X = x] = \binom{n}{x} p^x (1-p)^{n-x} \quad (70)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \sum_{k=0}^x \binom{n}{k} p^k (1-p)^{n-k} \quad (71)$$

Tomamos $r \sim U(0, 1)$. Como $F(x)$ es discreta, la función inversa $F^{-1}(x)$ se obtiene por iteración (búsqueda). Se aplica la misma regla que en la Pascal: se define como el menor valor entero x que cumple la condición $F(x) \geq r$:

$$F(x-1) < r \leq F(x) \quad (72)$$

El algoritmo es el siguiente:

1. Generar $r \sim \text{Uniforme}(0, 1)$.
2. Iniciar en $x = 0$ con $F(x) = 0$.
3. En cada paso sumar $P(X = x)$ a $F(x)$.
4. Si $F(x) \geq r$, devolver x .
5. Si no, incrementar x y repetir desde el paso 3.

2.2.7. Distribución Hipergeométrica

Dada la función de densidad $f(x)$ de la distribución Hipergeométrica:

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}, \quad x = \max(0, n+K-N), \dots, \min(n, K) \quad (73)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \sum_{k=x_{\min}}^x \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} \quad (74)$$

Tomamos $r \sim \text{Uniforme}(0, 1)$. Como $F(x)$ es discreta, se aplica la misma regla que en Binomial y Pascal:

$$F(x-1) < r \leq F(x) \quad (75)$$

La búsqueda termina en $x = \min(n, K)$ como máximo, ya que $F(\min(n, K)) = 1 \geq r$ siempre. El algoritmo es el siguiente:

1. Generar $r \sim \text{Uniforme}(0, 1)$.
2. Calcular $x_{\min} = \max(0, n + K - N)$ e iniciar con $F(x) = 0$.
3. En cada paso sumar $P(X = x)$ a $F(x)$.
4. Si $F(x) \geq r$, devolver x .
5. Si no, incrementar x y repetir desde el paso 3.

2.2.8. Distribución de Poisson

Dada la función de densidad $f(x)$ de la distribución de Poisson:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots \quad (76)$$

con función de distribución acumulada $F(x)$:

$$F(x) = \sum_{k=0}^x \frac{e^{-\lambda} \lambda^k}{k!} \quad (77)$$

Tomamos $r \sim \text{Uniforme}(0, 1)$. Como $F(x)$ es discreta, se aplica la misma regla que en las distribuciones discretas anteriores. El algoritmo es el siguiente:

1. Generar $r \sim \text{Uniforme}(0, 1)$.
2. Iniciar en $x = 0$ con $F(x) = 0$.
3. En cada paso sumar $P(X = x)$ a $F(x)$.
4. Si $F(x) \geq r$, devolver x .
5. Si no, incrementar x y repetir desde el paso 3.

2.2.9. Distribución Empírica Discreta

Dada la función de densidad $f(x)$ de la distribución Empírica Discreta:

$$P(X = x_i) = p_i, \quad i = 1, 2, \dots, n \quad (78)$$

con la condición de que:

$$\sum_{i=1}^n p_i = 1, \quad p_i \geq 0 \quad (79)$$

con función de distribución acumulada $F(x)$:

$$F(x_i) = \sum_{k=1}^i p_k \quad (80)$$

Tomamos $r \sim \text{Uniforme}(0, 1)$. Se aplica la misma regla que en todas las discretas anteriores. El algoritmo es el siguiente:

1. Generar $r \sim \text{Uniforme}(0, 1)$.
2. Iniciar en $i = 1$ con $F = 0$.
3. En cada paso sumar p_i a F .
4. Si $F \geq r$, devolver x_i .
5. Si no, incrementar i y repetir desde el paso 3.

2.3. Método de rechazo (deducción matemática)

El objetivo es generar una variable aleatoria X que siga una función de densidad de probabilidad objetivo $f(x)$.

Si $f(x)$ es una función acotada y x tiene además un rango finito con $a \leq x \leq b$, entonces se puede utilizar la técnica de rechazos para generar los valores de variables aleatorias. La aplicación de esta técnica requiere que proceda de acuerdo con las siguientes etapas:

1. Normalizar el rango de f mediante un factor de escala c tal que $c \cdot f(x) \leq 1$, $a \leq x \leq b$.
2. Definir a x como una función lineal de r :

$$x = a + (b - a)r \quad (81)$$

3. Generar parejas de números aleatorios (r_1, r_2) .
4. Siempre que se encuentre una pareja de números aleatorios que satisfagan la relación

$$r_2 \leq c \cdot f[a + (b - a)r_1] \quad (82)$$

dicho par será aceptado y se utilizará $x = a + (b - a) \cdot r_1$ como el valor generado de la variable aleatoria.

La teoría sobre la que se apoya este método se basa en el hecho ya conocido relativo a la probabilidad de que r sea menor o igual a $c \cdot f(x)$:

$$P[r \leq c \cdot f(x)] = c \cdot f(x) \quad (83)$$

En consecuencia, si x se elige al azar dentro del rango (a, b) de acuerdo con la ecuación $x = a + (b - a)r$ y en el caso de que $r > c \cdot f(x)$ se rechaza, la función de densidad de probabilidad de los valores de x aceptados deberá ser igual a $f(x)$.

Tocher ha demostrado que la esperanza matemática del número de intentos que se realizan, antes de encontrar una pareja exitosa es igual a $1/c$. Esto implica que para ciertas funciones de densidad de probabilidad este método puede resultar sumamente ineficaz.

2.3.1. Distribución de Probabilidad Uniforme

Para aplicar el método de rechazo a la distribución uniforme continua, partimos de su función de densidad de probabilidad objetivo, la cual está definida en el intervalo cerrado $[a, b]$:

$$f(x) = \frac{1}{b - a} \quad \forall x \in [a, b] \quad (84)$$

1. Buscamos un factor de escala c tal que el máximo de la curva escalada sea menor o igual a 1: $c \cdot f(x) \leq 1$.

Sustituyendo la función de densidad: $c \cdot \frac{1}{b - a} \leq 1$.

Para optimizar el algoritmo y hacer que el “techo” sea exactamente 1, despejamos el factor de escala óptimo:

$$c = b - a \quad (85)$$

Si comprobamos la función escalada con este valor de c , obtenemos:

$$c \cdot f(x) = (b - a) \cdot \frac{1}{b - a} = 1 \quad (86)$$

2. Mapeamos el primer número pseudoaleatorio r_1 al rango deseado:

$$x = a + (b - a) \cdot r_1 \quad (87)$$

3. La pareja de números pseudoaleatorios (r_1, r_2) será aceptada si se cumple la relación $r_2 \leq c \cdot f(x)$. Reemplazando por los valores obtenidos en el primer paso, la condición se reduce a:

$$r_2 \leq 1 \quad (88)$$

Dado que por definición cualquier número pseudoaleatorio r_2 generado por la computadora pertenece al intervalo $[0, 1)$, la inecuación se cumplirá en el 100 % de los casos.

Esta deducción demuestra matemáticamente que aplicar el método de rechazo para generar valores de una distribución uniforme resulta en una redundancia donde no se rechaza a ningún candidato. La eficiencia del algoritmo es máxima, comprobando empíricamente el teorema de Tocher.

2.3.2. Distribución Exponencial

Para aplicar el método de rechazo a la distribución exponencial continua, partimos de su función de densidad de probabilidad objetivo. Dado que la técnica de rechazos requiere que la variable tenga un rango finito $[a, b]$, definimos obligatoriamente el límite inferior $a = 0$ (ya que no existen ocurrencias negativas) y truncamos la cola infinita en un límite superior b lo suficientemente grande para contener la mayor parte de la probabilidad:

$$f(x) = \lambda e^{-\lambda x} \quad \forall x \in [0, b] \quad (89)$$

1. Buscamos un factor de escala c tal que el máximo de la curva escalada sea menor o igual a 1: $c \cdot f(x) \leq 1$.

Como la función exponencial decrece monótonamente, su valor máximo absoluto se encuentra siempre en el límite inferior, es decir, cuando $x = 0$:

$$f(0) = \lambda e^{-\lambda \cdot 0} = \lambda \quad (90)$$

Para optimizar el algoritmo y hacer que el “techo” superior sea exactamente 1, determinamos que el factor de escala óptimo es:

$$c = \frac{1}{\lambda} \quad (91)$$

Si comprobamos la función escalada con este valor de c , obtenemos la simplificación matemática clave de este método:

$$c \cdot f(x) = \frac{1}{\lambda} \cdot \lambda e^{-\lambda x} = e^{-\lambda x} \quad (92)$$

2. Mapeamos el primer número pseudoaleatorio r_1 al rango finito que establecimos. Sabiendo que $a = 0$, la ecuación general se reduce a:

$$x = b \cdot r_1 \quad (93)$$

3. Siempre que se encuentre una pareja de números pseudoaleatorios (r_1, r_2) que satisfaga la relación $r_2 \leq c \cdot f(x)$, dicho par será aceptado. Reemplazando por la función normalizada obtenida en el primer paso, la condición final queda definida como:

$$r_2 \leq e^{-\lambda x} \quad (94)$$

O expresado en función exclusivamente de la pareja de pseudoaleatorios generada:

$$r_2 \leq e^{-\lambda(b \cdot r_1)} \quad (95)$$

A diferencia de lo demostrado con la distribución uniforme, aquí la inecuación no se cumplirá en todos los casos. A medida que el candidato generado r_1 acerque la coordenada x hacia el límite b , el valor del techo $e^{-\lambda x}$ decaerá rápidamente asintóticamente hacia cero, aumentando de forma exponencial la probabilidad de que el número pseudoaleatorio r_2 sea mayor y, por ende, rechazado.

Esto ilustra el postulado de Tocher, demostrando que la ineficacia del método de rechazo aumenta drásticamente cuando el área de la caja delimitadora es significativamente mayor que el área bajo la curva de la función de densidad acotada.

2.3.3. Distribución de Probabilidad Normal

Para aplicar el método de rechazo a la distribución normal, partimos de su función de densidad de probabilidad objetivo. Dado que esta distribución se define en un rango infinito $(-\infty, \infty)$, para su implementación mediante esta técnica hay que truncar la distribución en un intervalo finito $[a, b]$ lo suficientemente amplio para asegurar que la masa de probabilidad fuera de ese rango sea despreciable:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \quad (96)$$

1. Buscamos un factor de escala c tal que el máximo de la curva escalada sea menor o igual a 1: $c \cdot f(x) \leq 1$.

Como el valor máximo de la función normal estándar ocurre en la media ($z = 0$) y es aproximadamente 0,3989, el factor de escala óptimo para que el “techo” de la función sea exactamente 1 es:

$$c = \sqrt{2\pi} \approx 2,5066 \quad (97)$$

2. Se genera un primer número pseudoaleatorio $r_1 \sim U(0, 1)$ y se proyecta linealmente al rango de interés $[a, b]$ para obtener un valor candidato z :

$$z = a + (b - a) r_1 \quad (98)$$

3. Se genera un segundo número pseudoaleatorio $r_2 \sim U(0, 1)$. La pareja de números (r_1, r_2) es aceptada si se satisface la relación de la función objetivo escalada:

$$r_2 \leq c \cdot f(z) \quad (99)$$

Sustituyendo los valores de la distribución normal, la condición de aceptación se simplifica:

$$r_2 \leq e^{-z^2/2} \quad (100)$$

4. Si la inecuación se cumple, el par es aceptado y se usa z como el valor generado de la variable aleatoria. Si no, el candidato se rechaza y se repite el procedimiento desde el paso 2 hasta obtener un valor válido.

2.4. Código Método Rechazo

2.4.1. Distribución de Probabilidad Uniforme

```
#Definicion de variables
a=0
b=10
candidatos_totales=500
aceptados_x = []
aceptados_y = []

rechazados_x = []
rechazados_y = []

for _ in range(candidatos_totales):
    r1 = random.random() # Eje X (0 a 1)

    r2 = random.random()

    # Transformamos r1 al rango [a, b]
    x_candidato = a + (b - a) * r1

    # El techo de la uniforme escalada es constante en 1.0
    techo = 1.0

    # Filtro de Aceptación/Rechazo
    if r2 <= techo:
        aceptados_x.append(x_candidato)
        aceptados_y.append(r2)
```

```
    else:
        rechazados_x.append(x_candidato)
        rechazados_y.append(r2)

print(f"De {candidatos_totales} intentos, se aceptaron
{len(aceptados_x)} números uniformes. Porcentaje de aceptación:
{len(aceptados_x) / candidatos_totales * 100:.2f}%")
```

2.4.2. Distribución de Probabilidad Normal

```
#Definicion de variables
a=-5
b=5
candidatos_totales=500
aceptados_x = []
aceptados_y = []

rechazados_x = []
rechazados_y = []

for _ in range(candidatos_totales):
    r1 = random.random()
    r2 = random.random()
    x_candidato = a + (b - a) * r1
    techo = math.exp(-0.5 * (x_candidato ** 2))
    if r2 <= techo:
        aceptados_x.append(x_candidato)
        aceptados_y.append(r2)
    else:
        rechazados_x.append(x_candidato)
        rechazados_y.append(r2)

print(f"De {candidatos_totales} intentos, se aceptaron
{len(aceptados_x)} números normales. Porcentaje de aceptación:
{len(aceptados_x) / candidatos_totales * 100:.2f}%")
```

3. Resultados

3.1. Método de Rechazo

Se usaron diagramas de dispersión para ver el comportamiento de los generadores basados en el método de rechazo (Uniforme, Exponencial y Normal). Los puntos verdes representan los valores aceptados que satisfacen la condición de aceptación $r_2 \leq \text{techo}$, y los puntos rojos representan los valores rechazados.

Distribución uniforme: El gráfico muestra una aceptación total, ya que el “techo” definido coincide con el límite superior de la función, eliminando los rechazos.




Figura 1: Método de Rechazo - Uniforme

Distribución normal: Los puntos aceptados muestran una campana de Gauss. La densidad de puntos rojos en las zonas de baja probabilidad confirma que funciona el filtro de aceptación/rechazo según la teoría de Tocher.




Figura 2: Método de Rechazo - Normal

Distribución exponencial: Los puntos aceptados muestran una curva decreciente. La densidad de puntos rojos en las zonas de baja probabilidad confirma que funciona el filtro de aceptación/rechazo según la teoría de Tocher.




Figura 3: Método de Rechazo - Exponencial

3.2. Transformada Inversa

Para las distribuciones discretas (Poisson, Binomial y Empírica) se usaron histogramas de frecuencia. En los 3 casos, las barras de los valores generados muestran una convergencia precisa con los puntos de la fórmula teórica.




Figura 4: Testeo de generador - Poisson




Figura 5: Testeo de generador - Binomial




Figura 6: Testeo de generador - Empírica discreta

4. Conclusiones

Este trabajo permitió profundizar en la generación de variables estocásticas, demostrando que es posible modelar una gran variedad de fenómenos reales a partir de un generador de números pseudoaleatorios uniformes $(0, 1)$ previamente validado.

A través de la implementación de los métodos propuestos por Naylor, concluimos:

El Método de la Transformada Inversa es el más simple y eficiente cuando la función acumulada puede invertirse fácilmente. Sin embargo, cuando esto no ocurre, como sucede con las distribuciones Gamma o Normal, el Método de Rechazo y las aproximaciones basadas en el Teorema del Límite Central resultan buenas alternativas para generar muestras que representen correctamente la distribución buscada.

Se comprobó empíricamente el teorema de Tocher, observando que la eficiencia del método de rechazo depende directamente del factor de escala (c). En una distribución uniforme prácticamente todos los valores son aceptados, mientras que en distribuciones como la Normal o la Exponencial es necesario descartar algunos candidatos, especialmente en las colas de la distribución, lo que hace que el proceso requiera más tiempo de cálculo.

El análisis visual mediante histogramas y scatter plots, complementado con pruebas de bondad de ajuste χ^2 , fue muy útil para verificar que los algoritmos no solo generen números al azar, sino que estos sigan el comportamiento esperado de cada distribución.

En conclusión, la generación de variables aleatorias con distribuciones específicas es una herramienta fundamental para la simulación. Estas técnicas permiten representar el comportamiento de sistemas reales y obtener resultados estadísticamente confiables sin tener que realizar experimentos directamente sobre la realidad, lo que reduce costos y facilita el análisis de distintos problemas.

Referencias

[1] Naylor, T.H. Naylor, t.h. técnicas de simulación en computadoras, 1982.